Guia de Econometria e Séries Temporais

Corte transversal, painel, séries temporais,
volatilidade e aprendizado de máquina

Material de estudo em português, com explicações originais,
experimentos numéricos conferidos e exercícios resolvidos

Livros de referência para aprofundamento: Wooldridge, Goldberger, Stachurski, Hanck et al., Hamilton, Lütkepohl, Cryer e Chan, Cowpertwait e Metcalfe, Mills, Tsay, Montgomery et al., Hang Chan, Hastie et al., Faloutsos et al., Faouzi e Janati.

Conteúdo

Antes de começar **1**

I Fundamentos **3**

1 Esperança condicional e projeção linear **4**

1.1 Para que serve a esperança condicional 4

1.2 A forma com erro 4

1.3 Efeitos parciais, elasticidades e semielasticidades 4

1.4 Projeção linear: o que o MQO realmente estima 5

2 Assintótica em linguagem simples **6**

2.1 Por que olhar para amostras grandes 6

2.2 Consistência não é ausência de viés 6

2.3 O padrão por trás de todos os erros-padrão 6

II Regressão e identificação **8**

3 MQO: o que estima, quando funciona e como calcular os erros-padrão **9**

3.1 O modelo e as hipóteses mínimas 9

3.2 Consistência em duas linhas 9

3.3 Erros-padrão: usual versus robusto 9

4 Variáveis omitidas e erro de medida **11**

4.1 Variável omitida 11

4.2 Variável proxy 11

4.3 Erro de medida clássico 11

5 Variáveis instrumentais e MQ2E **13**

5.1 A ideia 13

5.2 O estimador de VI simples 13

5.3 MQ2E (mínimos quadrados em dois estágios) 13
5.4 Instrumentos fracos 14

III Dados em painel **15**

6 Dados em painel **16**

6.1 O modelo de efeitos não observados 16
6.2 Os estimadores principais 16
6.3 Efeitos fixos ou aleatórios? Teste de Hausman e a alternativa de Mundlak 17

IV Séries temporais **18**

7 Séries temporais: estacionariedade e autocorrelação **19**

7.1 Por que séries temporais pedem ferramentas próprias 19
7.2 Estacionariedade fraca 19
7.3 Quatro séries que você precisa conhecer 19
7.4 AR(2) e a condição de estacionariedade 20
7.5 Assinaturas na FAC e na FACP 20

8 ARMA, ARIMA e a metodologia Box–Jenkins **22**

8.1 O modelo ARMA e o operador de defasagem 22
8.2 ARIMA: o que a letra “I” faz 22
8.3 O ciclo Box–Jenkins em quatro passos 22
8.4 Sazonalidade 23

9 Previsão **24**

9.1 O melhor previsor 24
9.2 Passeio aleatório e ARIMA 24
9.3 Como avaliar previsões 25

10 Raízes unitárias, regressão espúria e cointegração **26**

10.1 Tendência determinística versus estocástica 26
10.2 Teste de Dickey–Fuller aumentado (ADF) 26

10.3 Regressão espúria 27
10.4 Cointegração 27

11 Vetores autorregressivos (VAR) 29

11.1 O modelo 29
11.2 Escolha do número de defasagens 29
11.3 Causalidade de Granger 29
11.4 Funções de resposta a impulso e decomposição da variância 30

12 Volatilidade: ARCH e GARCH 31

12.1 O problema 31
12.2 ARCH(1) e GARCH(1,1) 31

13 Aprendizado de máquina para séries temporais 33

13.1 O que muda quando os dados têm ordem 33
13.1.1 Validação cruzada que respeita o tempo 33
13.1.2 Árvores não extrapolam 33
13.1.3 Construção das variáveis explicativas 34
13.2 Duas famílias úteis 34

V Consulta rápida 36

14 Cola de armadilhas e convenções 37

Antes de começar

Este guia foi escrito do zero, em português, com explicações próprias, para você aprender econometria de corte transversal, dados em painel e séries temporais. Ele *não* é uma tradução de nenhum dos livros. Os livros enviados são a base de leitura aprofundada. Este material é o caminho didático para chegar até eles.

Como o guia está organizado

Cada capítulo segue a mesma ordem: a ideia em linguagem simples, a matemática essencial, um experimento numérico que confirma a teoria, as armadilhas mais comuns e exercícios com solução. As caixas coloridas têm função fixa:

Intuição

Explica o *porquê* antes da fórmula.

Armadilha

Erros frequentes, inclusive os que aparecem em livros e em manuais de software.

Conferido por simulação

Resultado que eu rodei no computador (Python) para ter certeza de que a afirmação está correta. Os números são de uma semente fixa, então variam um pouco se você repetir.

Mapa dos livros: onde aprofundar cada tema

Tema	Onde ler mais
Probabilidade e álgebra linear de base	Stachurski (*Econometric Theory*, notas de curso), partes I e II; Goldberger
Regressão, MQO, VI	Wooldridge (cap. 4 e 5 da 1ª edição); Hanck et al. (cap. 4 a 9 e 12)
Dados em painel	Wooldridge (cap. 10 e 11); Hanck et al. (cap. 10)
ARMA, ARIMA, Box–Jenkins	Cryer e Chan (cap. 4 a 9); Mills (cap. 3, 4 e 7); Hamilton (cap. 3 e 4)
Raízes unitárias e cointegração	Hamilton (cap. 17 a 19); Mills (cap. 14); Hanck et al. (cap. 14 e 16)
VAR	Lütkepohl (*New Introduction to Multiple Time Series Analysis*); Hamilton (cap. 11); Mills (cap. 13)
Volatilidade (ARCH/GARCH)	Tsay (*Analysis of Financial Time Series*); Mills (cap. 10); Hamilton (cap. 21)
Aprendizado de máquina	Hastie, Tibshirani e Friedman (*Elements of Statistical Learning*); tutorial de Faloutsos et al. sobre previsão em larga escala; Faouzi e Janati (pacote `pyts`)

Duas observações sobre os livros

Edição do Wooldridge. O arquivo que você enviou é a 1ª edição de *Econometric Analysis of Cross Section and Panel Data* (2002, com impressão de 2004). Existe uma 2ª edição, de 2010, bem mais extensa. Os conceitos que uso aqui (MQO, VI, efeitos fixos e aleatórios) estão nas duas, mas a numeração de capítulos e alguns tópicos avançados mudam. Para o trabalho aplicado atual, vale ter a 2ª edição.

Sobre "corrigir os erros dos livros". Eu não auditei milhares de páginas atrás de erratas, e não vou fingir que sim. O que fiz foi (i) conferir por simulação toda fórmula e todo número que aparece neste guia e (ii) destacar, na caixa *Armadilha*, os pontos onde os livros divergem entre si ou onde um erro é comum. O mais importante deles é o sinal do coeficiente de médias móveis, que muda de livro para livro (capítulo 7). Também não li os livros por inteiro: usei os sumários para montar o mapa acima e conferi diretamente em Cryer–Chan e em Mills a convenção de sinal do MA. Se você encontrar algo que não bate com seu livro, confie na simulação e na derivação, não no meu texto.

Notação

Vetores e matrizes em negrito quando for útil. $\mathbb{E}(\cdot)$ é esperança, Var variância, Cov covariância, plim limite em probabilidade. $\hat{\beta}$ é um estimador e β o parâmetro verdadeiro. Em séries temporais, B é o operador de defasagem: $By_t = y_{t-1}$.

Parte I

Fundamentos

Capítulo 1

Esperança condicional e projeção linear

1.1 Para que serve a esperança condicional

Quase toda a econometria tenta responder: *dado o que sei sobre x, qual é o valor típico de y?* A resposta matemática é a esperança condicional $m(x) = \mathbb{E}(y \mid x)$.

Intuição

Imagine separar as pessoas por anos de estudo (x) e calcular o salário médio de cada grupo (y). A lista desses salários médios, um por grupo, é $m(x)$. Ela não diz nada sobre causa. Diz apenas qual é o salário médio de quem tem aquela escolaridade.

Resultado 1.1 (A esperança condicional é o melhor preditor). *Para qualquer função $g(x)$,*

$$\mathbb{E}[(y - g(x))^2] \;=\; \mathbb{E}[(y - m(x))^2] \;+\; \mathbb{E}[(m(x) - g(x))^2] \;\geq\; \mathbb{E}[(y - m(x))^2].$$

Logo $m(x)$ minimiza o erro quadrático médio entre todas as funções de x.

Por quê? Some e subtraia $m(x)$ dentro do quadrado. O termo cruzado tem esperança zero porque $\mathbb{E}(y - m(x) \mid x) = 0$.

1.2 A forma com erro

Defina $u = y - m(x)$. Então $y = m(x) + u$ com $\mathbb{E}(u \mid x) = 0$. Duas consequências usadas o tempo todo:

- $\mathbb{E}(u) = 0$ (pela lei das esperanças iteradas, $\mathbb{E}(u) = \mathbb{E}[\mathbb{E}(u \mid x)]$);
- $\mathrm{Cov}(u, h(x)) = 0$ para qualquer função h (o erro não tem nenhuma relação com x, nem linear nem não linear).

1.3 Efeitos parciais, elasticidades e semielasticidades

Se $m(x_1, x_2)$ é a esperança condicional, o efeito parcial de x_1 é $\partial m / \partial x_1$. Com variável em log:

Modelo	Coeficiente β_1 mede	Nome
$y = \beta_0 + \beta_1 x_1$	variação de y por unidade de x_1	efeito marginal
$\log y = \beta_0 + \beta_1 x_1$	$\approx 100\beta_1\%$ de variação em y por unidade de x_1	semielasticidade
$\log y = \beta_0 + \beta_1 \log x_1$	% de variação em y por 1% em x_1	elasticidade

Se o modelo tem interação ou termo quadrático, o efeito de x_1 muda com os valores das variáveis. Nesse caso reporte o **efeito parcial médio** (EPM): a média do efeito parcial sobre a distribuição de x.

1.4 Projeção linear: o que o MQO realmente estima

Nem sempre $m(x)$ é linear. Mesmo assim, existe sempre a melhor aproximação linear no sentido do erro quadrático médio:

$$L(y \mid 1, x) = \beta_0 + x\beta, \qquad \beta = \left[\mathbb{E}(x'x)\right]^{-1}\mathbb{E}(x'y) \quad \text{(com } x \text{ incluindo o 1)}.$$

Intuição

A projeção linear é a reta (ou hiperplano) que melhor *resume* a nuvem de pontos, mesmo que a nuvem seja curva. O MQO estima exatamente essa reta. Só quando $m(x)$ é de fato linear é que essa reta coincide com a esperança condicional.

Armadilha: "linear" não é "causal"

O coeficiente da projeção é sempre bem definido. Isso não o transforma em efeito causal. Para que β tenha leitura causal, é preciso um argumento extra sobre por que os outros fatores que afetam y não se movem junto com x (capítulos 3 a 5).

Exercício 1.1. Seja $x \sim N(0,1)$ e $y = x^2$ (sem ruído). Qual é a inclinação da projeção linear de y sobre x? E o que isso diz sobre dependência entre y e x?

Solução. $\mathrm{Cov}(x, x^2) = \mathbb{E}(x^3) - \mathbb{E}(x)\mathbb{E}(x^2) = 0$, pois os momentos ímpares de uma normal centrada são nulos. Logo a inclinação é zero e a projeção é a constante $\mathbb{E}(y) = 1$. Porém y é função exata de x. Uma correlação (ou inclinação) nula **não** significa independência. É o exemplo mais curto de por que a reta pode esconder uma relação forte.

Exercício 1.2. Mostre que, se $\mathbb{E}(u \mid x) = 0$, então $\mathrm{Cov}(u, x^2) = 0$.

Solução. $\mathrm{Cov}(u, x^2) = \mathbb{E}(ux^2) - \mathbb{E}(u)\mathbb{E}(x^2)$. Pela lei das esperanças iteradas, $\mathbb{E}(ux^2) = \mathbb{E}[x^2\mathbb{E}(u \mid x)] = 0$, e $\mathbb{E}(u) = 0$. Portanto a covariância é nula.

Capítulo 2

Assintótica em linguagem simples

2.1 Por que olhar para amostras grandes

Com amostras pequenas, só conseguimos propriedades exatas se fizermos hipóteses fortes, como erros normais. Com amostras grandes, a matemática fica mais leve e as hipóteses, mais realistas. Quatro ferramentas bastam para o curso inteiro.

Ferramenta	**O que diz**
Lei dos grandes números (LGN)	A média amostral $\bar{x}_n$ converge em probabilidade para $\mathbb{E}(x)$.
Teorema central do limite (TCL)	$\sqrt{n}(\bar{x}_n - \mu)$ converge em distribuição para $N(0, \sigma^2)$, qualquer que seja a distribuição de x (com variância finita).
Teorema de Slutsky	Se $a_n \to_p a$ e $b_n \to_d b$, então $a_n b_n \to_d ab$ e $a_n + b_n \to_d a+b$. Permite trocar parâmetros desconhecidos por estimativas consistentes.
Método delta	Se $\sqrt{n}(\hat{\theta}-\theta) \to_d N(0, V)$, então $\sqrt{n}(g(\hat{\theta})-g(\theta)) \to_d N(0, g'(\theta)^2 V)$.

2.2 Consistência não é ausência de viés

- **Não viesado**: $\mathbb{E}(\hat{\theta}) = \theta$ para um tamanho de amostra fixo.
- **Consistente**: $\hat{\theta} \to_p \theta$ quando $n \to \infty$.

Um estimador pode ter um tipo e não o outro. A média de apenas as duas primeiras observações é não viesada e não é consistente. O estimador $\frac{1}{n}\sum(x_i - \bar{x})^2$ da variância é viesado em amostras finitas e é consistente. Em econometria aplicada, consistência é o que costuma importar, porque quase nenhum estimador útil é exatamente não viesado.

2.3 O padrão por trás de todos os erros-padrão

A grande maioria dos estimadores que veremos satisfaz

$$\sqrt{n}(\hat{\beta} - \beta) \;\to_d\; N(0,\; A^{-1}BA^{-1}),$$

em que A é a "matriz de curvatura" e B é a variância do escore. Esse formato "sanduíche" reaparece no MQO com erros robustos (cap. 3), em VI (cap. 5) e em painel com erros agrupados (cap. 6). Quando a hipótese de homocedasticidade vale, B é proporcional a A e a expressão se simplifica para $\sigma^2 A^{-1}$.

Exercício 2.1. Seja x_i i.i.d. com média $\mu = 2$ e variância $\sigma^2 = 9$. Qual é o erro-padrão aproximado de $\bar{x}$ com $n = 400$ e qual é um intervalo de 95% se $\bar{x} = 2{,}3$?

Solução. ep $= \sigma/\sqrt{n} = 3/20 = 0{,}15$. Intervalo aproximado: $2{,}3 \pm 1{,}96 \times 0{,}15 = [2{,}006;\ 2{,}594]$. Se σ fosse desconhecido, trocaríamos por um estimador consistente (Slutsky) e o resultado seria o mesmo em grandes amostras.

Parte II

Regressão e identificação

Capítulo 3

MQO: o que estima, quando funciona e como calcular os erros-padrão

3.1 O modelo e as hipóteses mínimas

Considere $y = x\beta + u$, em que $x = (1, x_1, \dots, x_k)$ é um vetor linha. O estimador de mínimos quadrados ordinários é $\hat{\beta} = (X'X)^{-1}X'y$.

As quatro hipóteses para consistência e normalidade assintótica, na versão de amostra aleatória:

1. $y = x\beta + u$ (o modelo é linear nos parâmetros);
2. os dados são uma amostra aleatória (observações independentes e identicamente distribuídas);
3. $\mathbb{E}(x'u) = 0$ (os regressores não são correlacionados com o erro);
4. $\mathbb{E}(x'x)$ tem posto cheio (sem colinearidade perfeita).

Armadilha: a hipótese condicional é mais forte do que o necessário

Muitos textos clássicos exigem $\mathbb{E}(u \mid x) = 0$ ou tratam x como fixo. Para *consistência*, basta $\mathbb{E}(x'u) = 0$, que é a hipótese de que a projeção linear está correta. $\mathbb{E}(u \mid x) = 0$ só é necessária se você quer interpretar $x\beta$ como a esperança condicional, ou se quer propriedades de amostra finita (não viés exato). Wooldridge insiste nessa distinção e ela vale a pena guardar.

3.2 Consistência em duas linhas

$$\hat{\beta} = \beta + \left(\tfrac{1}{n}\sum x_i'x_i\right)^{-1}\left(\tfrac{1}{n}\sum x_i'u_i\right) \;\to_p\; \beta + \left[\mathbb{E}(x'x)\right]^{-1}\mathbb{E}(x'u) = \beta.$$

O segundo fator tende a zero pela LGN *se* $\mathbb{E}(x'u) = 0$. Todo o resto do curso (variáveis omitidas, erro de medida, VI) é uma história sobre o que acontece quando essa condição falha.

3.3 Erros-padrão: usual versus robusto

- **Usual** (homocedástico): $\widehat{\mathrm{Var}}(\hat{\beta}) = \hat{\sigma}^2(X'X)^{-1}$. Vale se $\mathrm{Var}(u \mid x)$ é constante.

- **Robusto a heterocedasticidade** (White/Eicker–Huber): $\widehat{\mathrm{Var}}(\hat{\beta}) = (X'X)^{-1}\Big(\sum \hat{u}_i^2 x_i' x_i\Big)(X'X)^{-1}$. Vale mesmo quando a variância do erro depende de x.

Conferido por simulação: erro-padrão usual subestima

$n = 5000$, $y = 1 + 2x + |x|\,\varepsilon$, com $\varepsilon \sim N(0,1)$ (variância do erro cresce com $|x|$). O coeficiente de x é estimado sem viés, mas o erro-padrão usual é 0,0143 e o robusto é 0,0248. O usual é cerca de 42% menor, e produziria testes t inflados e intervalos curtos demais.

Por que Gauss–Markov importa menos do que parece

O teorema de Gauss–Markov diz que o MQO é o melhor estimador linear não viesado *se* há homocedasticidade. Com heterocedasticidade ele continua consistente, apenas deixa de ser o mais eficiente, e o erro-padrão usual deixa de ser válido. Por isso, na prática, o hábito moderno é: estimar por MQO e reportar erros robustos.

Armadilhas frequentes

- **R^2 alto não valida causalidade.** Ele mede ajuste, não identificação.
- **Teste de heterocedasticidade antes de escolher o erro-padrão** é desnecessário: o robusto é válido nos dois casos.
- **Séries temporais ou painéis**: o erro-padrão robusto a heterocedasticidade *não* corrige correlação serial. Use erros robustos a autocorrelação (HAC) ou agrupados (cluster).

Exercício 3.1. Um modelo $y = \beta_0 + \beta_1 x + u$ foi estimado com $n = 100$, $\hat{\beta}_1 = 0{,}8$ e erro-padrão robusto 0,3. Teste $H_0 : \beta_1 = 0$ a 5%.

Solução. $t = 0{,}8/0{,}3 \approx 2{,}67 > 1{,}96$. Rejeita-se H_0 a 5%. Intervalo de 95%: $0{,}8 \pm 1{,}96 \times 0{,}3 = [0{,}21;\ 1{,}39]$.

Capítulo 4

Variáveis omitidas e erro de medida

4.1 Variável omitida

Suponha que o modelo verdadeiro seja $y = \beta_0 + \beta_1 x + \beta_2 z + u$, mas você não observa z e roda y contra x. Seja δ_1 a inclinação da regressão de z sobre x. Então

$$\operatorname{plim} \hat{\beta}_1^{\text{curto}} = \beta_1 + \beta_2\, \delta_1, \qquad \delta_1 = \frac{\operatorname{Cov}(x, z)}{\operatorname{Var}(x)}.$$

O viés é o produto de dois fatores: o efeito de z sobre y (β_2) e a associação entre z e x (δ_1). Se qualquer um dos dois for zero, não há viés.

Conferido por simulação

$x = 0{,}6z + \epsilon$, com $z, \epsilon \sim N(0,1)$ independentes, e $y = 1 + 2x + 1{,}5z + u$. Teoria: $\delta_1 = 0{,}6/1{,}36 = 0{,}441$, logo $\operatorname{plim} \hat{\beta}_1^{\text{curto}} = 2 + 1{,}5 \times 0{,}441 = 2{,}662$. Com 2 milhões de observações, a regressão curta dá 2,662. Incluindo z, o coeficiente volta para 2,01 (em $n = 5000$).

Intuição

Sem z na equação, x "pega carona" no efeito de z sobre y porque os dois andam juntos. Quanto mais forte a carona, maior o viés. O sinal do viés é o sinal de $\beta_2 \delta_1$: se os dois são positivos, o MQO superestima.

4.2 Variável proxy

Se z não é observada, mas você tem uma proxy w (por exemplo, nota de teste para habilidade), incluir w pode reduzir ou eliminar o viés. Funciona se (i) w é *redundante* na equação de y quando z está presente e (ii) z é, condicionalmente, linearmente relacionada a w sem depender de x. Se (ii) falha, a proxy pode até piorar, pois um controle imperfeito deixa viés residual.

4.3 Erro de medida clássico

Há dois casos com consequências muito diferentes.

- **Erro na variável dependente**, $y = y^* + e$ com e não correlacionado com x: o MQO continua consistente e só perde precisão.
- **Erro numa variável explicativa**, $x = x^* + v$ com v independente de x^* e de u: o MQO é

atenuado em direção a zero:

$$\operatorname{plim} \hat{\beta}_1 = \beta_1 \cdot \frac{\sigma^2_{x^*}}{\sigma^2_{x^*} + \sigma^2_v}.$$

O fator entre parênteses é a "razão de confiabilidade", sempre entre 0 e 1.

Conferido por simulação

$x^* \sim N(0,1)$, $y = 1 + 2x^* + u$, e $x = x^* + v$ com $v \sim N(0,1)$. A razão de confiabilidade é $1/(1+1) = 0{,}5$, logo o MQO deve convergir para $2 \times 0{,}5 = 1{,}0$. Resultado: 0,995.

Armadilha

A atenuação vale para o regressor com erro. Se há *outros* regressores correlacionados com ele, o viés pode contaminar os demais coeficientes em direções que não são óbvias. E, se o erro de medida for correlacionado com o valor verdadeiro ("erro não clássico"), nem o sinal da atenuação é garantido.

Exercício 4.1. Num modelo em que $\beta_1 = 0{,}5$, $\beta_2 = 2$, $\operatorname{Var}(x) = 4$ e $\operatorname{Cov}(x, z) = 1$, qual é o limite em probabilidade do MQO de y contra x se z for omitida?

Solução. $\delta_1 = 1/4 = 0{,}25$. $\operatorname{plim} \hat{\beta}_1 = 0{,}5 + 2 \times 0{,}25 = 1{,}0$. O MQO dobra o efeito verdadeiro.

Exercício 4.2. Um economista mede renda com erro e obtém $\hat{\beta} = 0{,}30$. Sabe que a confiabilidade da medida é 0,6. Qual seria uma estimativa corrigida da atenuação?

Solução. $\hat{\beta}/0{,}6 = 0{,}30/0{,}6 = 0{,}50$, supondo erro clássico e um único regressor. Na prática, a confiabilidade precisa vir de fora (dados repetidos, validação ou um instrumento).

Capítulo 5

Variáveis instrumentais e MQ2E

5.1 A ideia

Quando x é correlacionado com u (endogeneidade), o MQO é inconsistente. Um **instrumento** z é uma variável que move x mas só afeta y *através de* x. Duas condições:

1. **Relevância**: $\mathrm{Cov}(z, x) \neq 0$ (condicional aos demais regressores exógenos). É testável.
2. **Exogeneidade**: $\mathrm{Cov}(z, u) = 0$. Num modelo com exatamente um instrumento por variável endógena, **não é testável**. É um argumento econômico, não estatístico.

5.2 O estimador de VI simples

Com um regressor e um instrumento,

$$\hat{\beta}_{VI} = \frac{\sum (z_i - \bar{z})(y_i - \bar{y})}{\sum (z_i - \bar{z})(x_i - \bar{x})} = \frac{\widehat{\mathrm{Cov}}(z, y)}{\widehat{\mathrm{Cov}}(z, x)}.$$

Intuição

O numerador mede quanto y muda quando z muda. O denominador mede quanto x muda quando z muda. A razão é o efeito de x sobre y que se extrai apenas da variação induzida por z. Essa é a versão "Wald" da VI.

Exercício 5.1 (Cálculo à mão)**.** $z = (0, 0, 1, 1, 1, 0)$, $x = (1, 2, 2, 4, 5, 3)$, $y = (2, 3, 6, 8, 9, 3)$. Calcule $\hat{\beta}_{VI}$ e compare com o MQO.

Solução. Médias: $\bar{z} = 0{,}5$, $\bar{x} = 2{,}833$, $\bar{y} = 5{,}167$. $\sum (z - \bar{z})(y - \bar{y}) = 7{,}5$ e $\sum (z - \bar{z})(x - \bar{x}) = 2{,}5$, logo $\hat{\beta}_{VI} = 7{,}5/2{,}5 = 3{,}0$. O MQO dá 1,677. A diferença entre os dois é grande, o que seria um sinal de endogeneidade se z fosse um bom instrumento (com $n = 6$, é apenas um exercício de contas).

5.3 MQ2E (mínimos quadrados em dois estágios)

Com vários instrumentos Z (que incluem os regressores exógenos), o estimador é

$$\hat{\beta}_{2SLS} = (X' P_Z X)^{-1} X' P_Z y, \qquad P_Z = Z(Z'Z)^{-1} Z'.$$

Em palavras: no primeiro estágio, regride-se cada variável endógena nos instrumentos; no segundo, usa-se o valor ajustado no lugar da variável original.

Conferido por simulação

Endogeneidade. $x = 0{,}8z + 0{,}7u + \epsilon$, $y = 1 + 2x + u$. O MQO converge para um valor errado, 2,33. O MQ2E recupera 2,02 (valor verdadeiro: 2). O estatístico F do primeiro estágio foi ≈ 2090.
Fórmula matricial. Com dois instrumentos ($n = 3000$), calculei $(X'P_ZX)^{-1}X'P_Zy$ na mão e com o pacote `linearmodels`. Os dois deram exatamente (0,97599; 1,97238) para (constante, inclinação).

5.4 Instrumentos fracos

Se $\mathrm{Cov}(z, x)$ é quase zero, o denominador da VI fica próximo de zero e o estimador se torna instável e viesado em direção ao MQO.

Instrumento fraco

Mesmo desenho, mas $x = 0{,}02z + 0{,}7u + \epsilon$. Aqui o MQO converge para $\approx 2{,}47$ (viés maior, pois x tem menos variação própria além de u). Numa simulação com $n = 5000$, o MQ2E deu 2,30: longe do verdadeiro (2) e puxado na direção do MQO. Com um instrumento tão fraco, o resultado de uma única amostra é muito instável. O instrumento existe, só que não ajuda.

Armadilhas clássicas de VI

- **Fazer o 2º estágio "na mão" e usar o erro-padrão do segundo MQO**: está errado. Os resíduos usados devem ser calculados com o x *original*, não com o valor ajustado. Use um comando de MQ2E, que faz a correção.
- **Regra "F do primeiro estágio > 10"** é um piso mínimo, não uma garantia. Com muitos instrumentos fracos, o viés persiste.
- **Teste de sobreidentificação** (Sargan/Hansen) só testa se os instrumentos concordam entre si. Se todos são inválidos do mesmo jeito, ele não percebe.
- **VI estima um efeito local**: com efeitos heterogêneos, estima o efeito médio entre quem muda de x por causa de z, não o efeito para toda a população.

Exercício 5.2. Por que é inadequado usar como instrumento uma variável que afeta y diretamente, mesmo que seja fortemente correlacionada com x?

Solução. Porque ela viola a exogeneidade: parte da correlação entre z e y não passa por x, e a razão $\mathrm{Cov}(z, y)/\mathrm{Cov}(z, x)$ passa a incluir esse canal direto. O estimador converge para $\beta + \mathrm{Cov}(z, u)/\mathrm{Cov}(z, x)$, e o numerador deixa de ser zero.

Parte III

Dados em painel

Capítulo 6

Dados em painel

6.1 O modelo de efeitos não observados

Temos N unidades (pessoas, firmas, municípios) observadas ao longo de T períodos:

$$y_{it} = x_{it}\beta + c_i + u_{it}.$$

c_i é o efeito não observado, constante no tempo (por exemplo, habilidade ou cultura da empresa). A pergunta central é: c_i **é correlacionado com** x_{it}**?**

6.2 Os estimadores principais

Estimador	**O que faz**	**Consistente se**
MQO agrupado (POLS)	Ignora c_i e roda MQO em tudo	$\mathbb{E}(x'_{it}(c_i + u_{it})) = 0$, isto é, c_i não correlacionado com x
Efeitos fixos (within)	Subtrai a média de cada unidade, eliminando c_i	Exogeneidade estrita: u_{it} não correlacionado com x_{is} em *todos* os períodos
Primeiras diferenças	Regride Δy_{it} em Δx_{it}	Idem; com $T = 2$ coincide com efeitos fixos
Efeitos aleatórios (GLS)	Subtrai uma fração θ da média da unidade	c_i não correlacionado com x_{it} (hipótese forte)

Intuição

Efeitos fixos só usa a variação *dentro* de cada unidade ao longo do tempo. Tudo que é fixo na unidade (sexo, local de nascimento, cultura) é neutralizado automaticamente, observado ou não. O preço: você perde a capacidade de estimar o efeito de qualquer variável que não muda no tempo, e perde variação se x muda pouco.

Conferido por simulação: efeito correlacionado

$N = 500$, $T = 6$, $y_{it} = 1 + 1{,}0\, x_{it} + c_i + u_{it}$, com $x_{it} = 0{,}7c_i +$ ruído (ou seja, c_i e x são correlacionados). O efeito verdadeiro é 1,0.

	MQO agrupado	Efeitos aleatórios	Efeitos fixos	Primeiras dif.
Estimativa	1,47	1,27	0,98	1,00

O MQO agrupado e os efeitos aleatórios ficam viesados porque assumem que c_i não se correlaciona com x. Efeitos fixos e primeiras diferenças recuperam o valor verdadeiro.

6.3 Efeitos fixos ou aleatórios? Teste de Hausman e a alternativa de Mundlak

O teste de Hausman compara efeitos fixos e aleatórios. Uma versão mais flexível, que na prática é mais usada, é a **abordagem de Mundlak**: inclua a média temporal $\bar{x}_i$ como regressor adicional e teste se o coeficiente de $\bar{x}_i$ é zero. Se for zero, efeitos aleatórios é razoável. O coeficiente de $\bar{x}_i$ mede a diferença entre os efeitos "entre unidades" e "dentro das unidades".

Conferido por simulação

Com c_i correlacionado a x, o coeficiente de $\bar{x}_i$ foi 1,06, com p-valor praticamente zero: rejeita-se efeitos aleatórios. Com c_i independente de x, o coeficiente foi 0,16 (p-valor 0,26): não se rejeita. O valor $\approx 1{,}06$ coincide com a teoria: diferença entre o efeito "entre" ($\approx 2{,}07$) e o efeito "dentro" (1).

Armadilhas em painel

- **Hausman clássico sob erros robustos/agrupados** deixa de ter a distribuição esperada. Prefira a versão por regressão (Mundlak) com erros agrupados.
- **Sempre agrupe os erros-padrão por unidade.** c_i gera correlação serial dentro da unidade, mesmo quando u_{it} é independente. O erro-padrão usual do MQO agrupado é tipicamente pequeno demais.
- **Exogeneidade estrita é forte.** Variáveis dependentes defasadas como regressor, ou *feedback* (y_{it} afeta $x_{i,t+1}$), a violam. Nesses casos, são necessários métodos de painel dinâmico (GMM), que fogem deste capítulo.
- **Efeitos fixos não resolvem endogeneidade que varia no tempo.**

Exercício 6.1. Com $T = 2$, mostre que o estimador de efeitos fixos é igual ao de primeiras diferenças.

Solução. Com $T = 2$, o desvio em relação à média é $\ddot{y}_{i1} = (y_{i1} - y_{i2})/2 = -\Delta y_i/2$ e $\ddot{y}_{i2} = \Delta y_i/2$ (e o mesmo vale para x). Então $\sum_t \ddot{x}_{it}\ddot{y}_{it} = \frac{1}{2}\Delta x_i \Delta y_i$ e $\sum_t \ddot{x}_{it}^2 = \frac{1}{2}(\Delta x_i)^2$. A razão das somas sobre i é $\sum \Delta x_i \Delta y_i / \sum (\Delta x_i)^2$, que é exatamente o MQO em primeiras diferenças.

Exercício 6.2. Por que o efeito de "anos de escolaridade" não pode ser estimado por efeitos fixos numa amostra de adultos que já terminaram os estudos?

Solução. Porque a escolaridade não varia dentro de cada pessoa ao longo do painel. Depois de subtrair a média da pessoa, o regressor vira zero para todos os períodos, e o coeficiente não é identificado.

Parte IV

Séries temporais

Capítulo 7

Séries temporais: estacionariedade e autocorrelação

7.1 Por que séries temporais pedem ferramentas próprias

Em corte transversal, observações independentes são razoáveis. Numa série, o valor de hoje depende do de ontem. Isso muda tudo: a mesma série é a nossa única amostra, e só podemos aprender com ela se o comportamento dela for, em algum sentido, estável ao longo do tempo. Essa estabilidade tem um nome: **estacionariedade**.

7.2 Estacionariedade fraca

Uma série $\{y_t\}$ é **fracamente estacionária** (ou estacionária em covariância) se

1. $\mathbb{E}(y_t) = \mu$ não depende de t;
2. $\mathrm{Var}(y_t) = \gamma_0$ não depende de t;
3. $\mathrm{Cov}(y_t, y_{t-k}) = \gamma_k$ depende só da defasagem k, não de t.

A **função de autocorrelação** (FAC) é $\rho_k = \gamma_k/\gamma_0$. A **FAC parcial** (FACP) em k é a correlação entre y_t e y_{t-k} depois de descontar o efeito das defasagens intermediárias.

FAC versus FACP

A FAC mistura efeitos diretos e indiretos: se hoje depende de ontem e ontem do anteontem, hoje e anteontem se correlacionam, mesmo sem ligação direta. A FACP tenta isolar só o elo direto.

7.3 Quatro séries que você precisa conhecer

Série	Definição	Propriedades
Ruído branco	$y_t = \varepsilon_t$, média 0, variância σ^2, sem correlação	$\rho_k = 0$ para $k \geq 1$. Bloco de construção de todos os modelos.
Passeio aleatório	$y_t = y_{t-1} + \varepsilon_t$	**Não** estacionário: variância $t\sigma^2$ cresce. Choques são permanentes.
AR(1)	$y_t = \phi y_{t-1} + \varepsilon_t$	Estacionário se $\lvert\phi\rvert < 1$; $\rho_k = \phi^k$ (decaimento geométrico).
MA(1)	$y_t = \varepsilon_t + \theta\varepsilon_{t-1}$	Sempre estacionário; $\rho_1 = \theta/(1+\theta^2)$ e $\rho_k = 0$ para $k \geq 2$.

Armadilha: o sinal do MA muda de livro para livro

Este guia usa $y_t = \varepsilon_t + \theta\varepsilon_{t-1}$ (sinal **positivo**), como Hamilton, o `arima` do R e o `statsmodels`. Cryer e Chan e Mills usam o sinal **negativo**, $y_t = \varepsilon_t - \theta\varepsilon_{t-1}$, herdado de Box e Jenkins. Com a convenção negativa, $\rho_1 = -\theta/(1+\theta^2)$. Se você copiar uma fórmula de um livro e um coeficiente de um software sem checar a convenção, o sinal do θ sai trocado. Ao ler uma saída de software, confirme sempre qual convenção ele adota.

Conferido: MA(1) com coeficiente 0,5

A fórmula dá $\rho_1 = 0{,}5/1{,}25 = 0{,}4$. A autocorrelação teórica calculada pelo `statsmodels` é 0,4. Note também que $\theta = 2$ dá $2/5 = 0{,}4$: **dois valores de θ (um e seu inverso) geram a mesma FAC**. Por isso exige-se invertibilidade, $|\theta| < 1$, para identificar o modelo. E o máximo de $|\rho_1|$ num MA(1) é 0,5.

7.4 AR(2) e a condição de estacionariedade

Para $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$, as três condições abaixo são equivalentes a "raízes do polinômio fora do círculo unitário" (o chamado triângulo de estacionariedade):

$$\phi_1 + \phi_2 < 1, \qquad \phi_2 - \phi_1 < 1, \qquad |\phi_2| < 1.$$

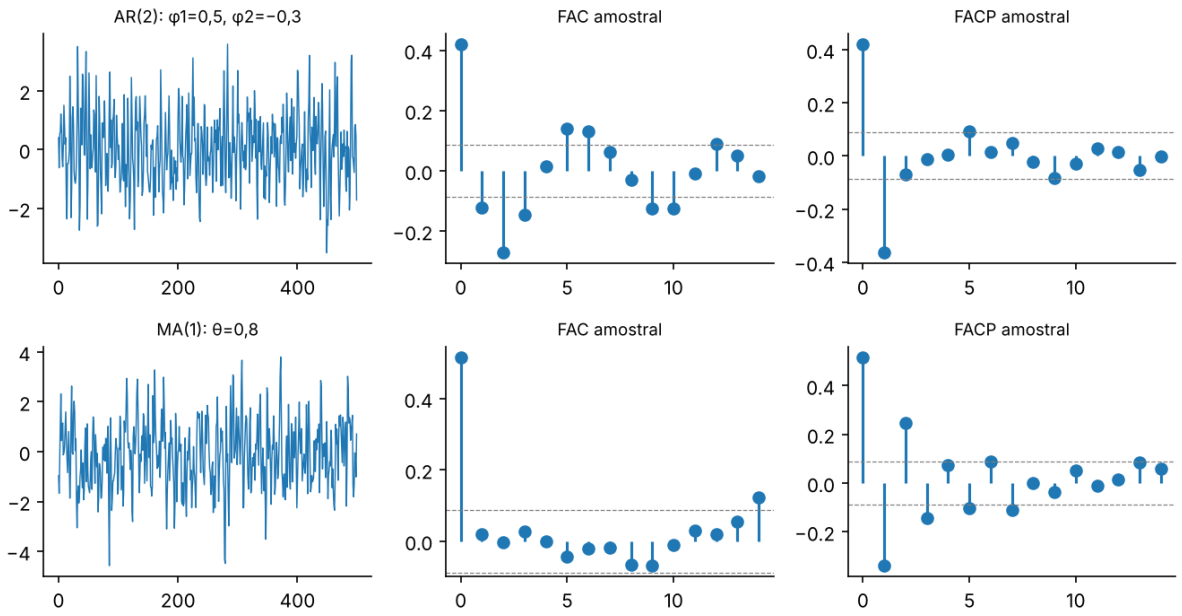
As equações de Yule–Walker dão $\rho_1 = \phi_1/(1-\phi_2)$ e $\rho_k = \phi_1\rho_{k-1} + \phi_2\rho_{k-2}$ para $k \geq 2$.

Conferido: AR(2) com coeficientes 0,5 e 0,3

Yule–Walker: $\rho_1 = 0{,}5/0{,}7 = 0{,}7143$ e $\rho_2 = 0{,}5 \times 0{,}7143 + 0{,}3 = 0{,}6571$. O `statsmodels` dá os mesmos valores. Testei também cinco pares (ϕ_1, ϕ_2) por cálculo das raízes: $(0{,}5; 0{,}3)$ é estacionário; $(1{,}2; -0{,}2)$, $(0{,}5; 0{,}6)$, $(1{,}0; 0)$ e $(-0{,}5; 0{,}5)$ não são, o que coincide com o triângulo.

7.5 Assinaturas na FAC e na FACP

Modelo	FAC	FACP
AR(p)	decai gradualmente	**corta** depois de p
MA(q)	**corta** depois de q	decai gradualmente
ARMA(p, q)	decai	decai



Séries simuladas (500 pontos) e suas FAC e FACP amostrais. Linha de cima: AR(2) ($\phi_1 = 0{,}5$, $\phi_2 = -0{,}3$): a FACP corta em 2. Linha de baixo: MA(1) ($\theta = 0{,}8$): a FAC corta em 1. As linhas pontilhadas são as bandas $\pm 1{,}96/\sqrt{n}$.

Armadilha

As bandas $\pm 1{,}96/\sqrt{n}$ valem sob a hipótese de ruído branco. Para uma série que *não* é ruído branco, as bandas corretas (de Bartlett) são mais largas, e em amostras curtas a FAC amostral é viesada para baixo. Interprete os gráficos como pista, não como veredito.

Exercício 7.1. Num AR(1) com $\phi = 0{,}6$ e $\sigma^2 = 1$, calcule γ_0, ρ_1 e ρ_3.

Solução. $\gamma_0 = \sigma^2/(1-\phi^2) = 1/0{,}64 = 1{,}5625$. $\rho_1 = 0{,}6$ e $\rho_3 = 0{,}6^3 = 0{,}216$.

Exercício 7.2. Um MA(1) tem $\theta = -0{,}4$ (convenção positiva). Qual é ρ_1? E se a convenção do livro fosse a negativa, com o mesmo número $-0{,}4$ impresso?

Solução. Convenção positiva: $\rho_1 = -0{,}4/(1+0{,}16) = -0{,}345$. Convenção negativa, com $\theta = -0{,}4$: $\rho_1 = -\theta/(1+\theta^2) = +0{,}345$. O mesmo número com convenções diferentes dá correlações de sinais opostos.

Capítulo 8

ARMA, ARIMA e a metodologia Box–Jenkins

8.1 O modelo ARMA e o operador de defasagem

Com $By_t = y_{t-1}$, um ARMA(p, q) escreve-se

$$\phi(B)\, y_t = \theta(B)\, \varepsilon_t, \qquad \phi(B) = 1 - \phi_1 B - \cdots - \phi_p B^p, \quad \theta(B) = 1 + \theta_1 B + \cdots + \theta_q B^q.$$

Duas exigências técnicas: **estacionariedade** (raízes de $\phi(B)$ fora do círculo unitário) e **invertibilidade** (raízes de $\theta(B)$ fora do círculo unitário). Esta última garante que o choque ε_t pode ser recuperado dos dados passados e que o modelo é identificado (vimos que θ e $1/\theta$ dão a mesma FAC).

8.2 ARIMA: o que a letra “I” faz

Se a série tem raiz unitária (passeio aleatório, tendência estocástica), diferencie: $\Delta y_t = y_t - y_{t-1}$. Um ARIMA$(p, d, q)$ é um ARMA(p, q) aplicado à série diferenciada d vezes. Quase nunca é necessário $d > 2$.

Superdiferenciação

Diferenciar uma série que já é estacionária cria uma raiz unitária no componente MA (o MA fica não invertível). Sintomas: FAC amostral com ρ_1 próximo de $-0{,}5$ e variância maior depois de diferenciar. Diferencie apenas o necessário.

8.3 O ciclo Box–Jenkins em quatro passos

1. **Especificação**: olhe o gráfico da série, decida a transformação (log para variância crescente) e o grau de diferenciação (teste de raiz unitária, capítulo 10). Use FAC e FACP para sugerir candidatos e critérios de informação (AIC, BIC) para compará-los.
2. **Estimação**: máxima verossimilhança ou mínimos quadrados condicionais.
3. **Diagnóstico**: os resíduos devem se parecer com ruído branco. Examine a FAC dos resíduos e faça o teste de Ljung–Box.
4. **Previsão**: apenas com o modelo validado (capítulo 9).

Armadilha: graus de liberdade do Ljung–Box

A estatística $Q = n(n+2)\sum_{k=1}^{m} \hat{\rho}_k^2/(n-k)$ é comparada com uma qui-quadrado com $m-p-q$ graus de liberdade, **não** com m, quando se testa resíduos de um ARMA(p,q) estimado. Usar m torna o teste conservador. Muitos softwares permitem informar $p+q$ para ajustar. Verifique.

AIC versus BIC

Ambos penalizam a complexidade: AIC $= -2\ln L + 2k$ e BIC $= -2\ln L + k\ln n$. O BIC pune mais e tende a escolher modelos menores e consistentes (encontra o modelo verdadeiro quando ele está entre os candidatos). O AIC tende a favorecer qualidade de previsão. Em caso de divergência, vale olhar os dois e preferir parcimônia.

8.4 Sazonalidade

Para dados com ciclo de período s (12 em dados mensais), usa-se o ARIMA sazonal $(p,d,q)(P,D,Q)_s$: acrescenta-se diferenciação sazonal $(1-B^s)$ e termos AR e MA nas defasagens $s, 2s, \ldots$ O exemplo clássico é o "modelo de linhas aéreas", um ARIMA$(0,1,1)(0,1,1)_{12}$ aplicado ao logaritmo da série. Sazonalidade também pode ser tratada com variáveis indicadoras ou com suavização exponencial (Holt–Winters).

Exercício 8.1. O modelo $y_t = 0{,}5y_{t-1} + \varepsilon_t + 0{,}4\varepsilon_{t-1}$ é estacionário e invertível?

Solução. Parte AR: $\phi(B) = 1 - 0{,}5B$, raiz $B = 2$, fora do círculo unitário: estacionário. Parte MA: $\theta(B) = 1 + 0{,}4B$, raiz $B = -2{,}5$, fora do círculo: invertível.

Exercício 8.2. Uma série tem FAC amostral que decai muito lentamente (0,95; 0,93; 0,91, …). O que isso sugere e qual é o próximo passo?

Solução. Autocorrelações muito persistentes são típicas de raiz unitária ou tendência. O próximo passo é aplicar um teste de raiz unitária (ADF, KPSS) e, se confirmada, diferenciar a série antes de identificar o ARMA.

Capítulo 9

Previsão

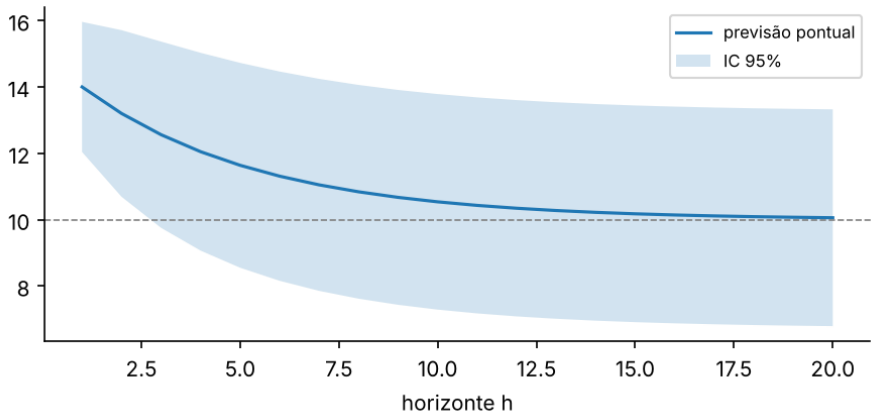
9.1 O melhor previsor

Para erro quadrático, o melhor previsor de y_{T+h} dado o passado é a esperança condicional $\mathbb{E}(y_{T+h} \mid y_T, y_{T-1}, \dots)$ (capítulo 1). Num AR(1) com média μ:

$$\hat{y}_{T+h} = \mu + \phi^h (y_T - \mu), \qquad \operatorname{Var}(e_{T+h}) = \sigma^2 \, \frac{1 - \phi^{2h}}{1 - \phi^2}.$$

Intuição

Quanto mais longe o horizonte, mais a previsão se aproxima da média de longo prazo, e mais a incerteza se aproxima da variância incondicional $\gamma_0 = \sigma^2/(1-\phi^2)$. Para h grande, o modelo não sabe mais do que a média.



AR(1) com $\mu = 10$, $\phi = 0{,}8$, $\sigma = 1$ e último desvio $y_T - \mu = 5$. A previsão decai para a média e o intervalo alarga e estabiliza.

Conferido por simulação: cobertura do intervalo

Simulei 4000 séries AR(1) com $\phi = 0{,}8$, previ $h = 3$ passos à frente e construí o intervalo de 95%. A cobertura empírica foi 95,0%. A variância teórica do erro para $h = 3$ é $(1 - 0{,}8^6)/(1 - 0{,}64) = 2{,}0496$, confirmada.

9.2 Passeio aleatório e ARIMA

Num passeio aleatório, $\hat{y}_{T+h} = y_T$ (previsão "ingênua") e $\operatorname{Var}(e_{T+h}) = h\sigma^2$. O intervalo cresce sem parar, o que reflete a natureza de choques permanentes. Modelos ARIMA com $d \geq 1$ têm

essa mesma propriedade, o que é muito diferente de um modelo estacionário.

Armadilha: intervalos otimistas

Os intervalos clássicos tratam os parâmetros estimados como verdadeiros e supõem que o modelo está certo. Com amostras curtas ou escolha de modelo feita com os mesmos dados, a cobertura real costuma ser menor do que a nominal. Em previsão séria, avalie a cobertura fora da amostra.

9.3 Como avaliar previsões

- **Fora da amostra, sempre.** O ajuste dentro da amostra premia modelos complicados.
- **Origem móvel (rolling origin)**: estime até t, preveja $t+1, \dots, t+h$, avance a origem e repita.
- **Métricas**: MAE e RMSE (mesma unidade da série); MAPE é intuitivo, mas explode se há valores próximos de zero e pune erros positivos e negativos de forma assimétrica; MASE compara com o previsor ingênuo e é comparável entre séries.
- **Sempre inclua um *benchmark***: ingênuo (último valor) ou sazonal ingênuo. Um modelo que não bate o ingênuo não serve.

Exercício 9.1. AR(1) com $\mu = 0$, $\phi = 0{,}8$, $\sigma^2 = 1$ e último valor $y_T = 5$. Dê a previsão para $h = 3$ e o intervalo de 95%.

Solução. Previsão: $0{,}8^3 \times 5 = 0{,}512 \times 5 = 2{,}56$. Variância do erro: 2,0496, desvio 1,4317. Intervalo: $2{,}56 \pm 1{,}96 \times 1{,}4317 = 2{,}56 \pm 2{,}806$, isto é, $[-0{,}25;\ 5{,}37]$.

Exercício 9.2. Um passeio aleatório tem $\sigma = 2$. Qual é o desvio-padrão do erro de previsão a 9 passos?

Solução. $\sqrt{h}\,\sigma = \sqrt{9} \times 2 = 6$.

Capítulo 10

Raízes unitárias, regressão espúria e cointegração

10.1 Tendência determinística versus estocástica

Duas séries podem "subir" por motivos muito diferentes.

- **Tendência determinística**: $y_t = a + bt +$ (estacionário). Os desvios da reta são temporários. Remover a tendência torna a série estacionária.
- **Tendência estocástica** (raiz unitária): $y_t = y_{t-1} + \varepsilon_t$. Os choques são permanentes. Remover uma reta *não* resolve; é preciso diferenciar.

Tratar uma como se fosse a outra gera erros graves de previsão e de inferência.

10.2 Teste de Dickey–Fuller aumentado (ADF)

Estima-se

$$\Delta y_t = \alpha + \gamma\, y_{t-1} + \sum_{j=1}^{p} \delta_j \Delta y_{t-j} + e_t,$$

e testa-se $H_0 : \gamma = 0$ (há raiz unitária) contra $\gamma < 0$ (estacionária). As defasagens extras servem para branquear os resíduos.

Armadilhas do ADF

- **A estatística t não segue a distribuição t nem a normal**. Os valores críticos são os de Dickey–Fuller, mais negativos (por exemplo, cerca de $-2{,}86$ a 5% com constante). Comparar com $-1{,}96$ rejeita demais.
- **Os termos determinísticos importam**: sem constante, com constante ou com tendência, os valores críticos mudam e a escolha errada distorce o teste.
- **Baixo poder**: o teste tem dificuldade em distinguir raiz unitária de uma raiz próxima de 1 (por exemplo, $\phi = 0{,}98$) em amostras moderadas.
- **KPSS inverte a hipótese nula** (a nula é estacionariedade). Usar os dois juntos é prática comum: ADF rejeita e KPSS não rejeita $\Rightarrow$ evidência favorável à estacionariedade.

Conferido por simulação

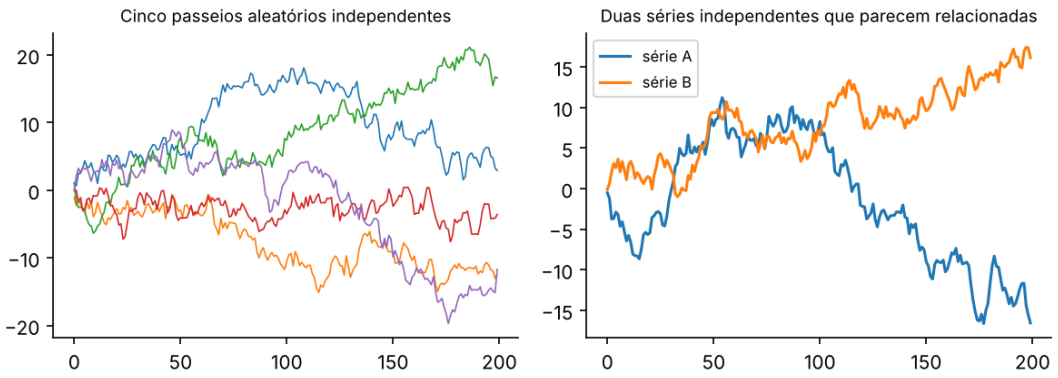
Num passeio aleatório de 300 pontos, o ADF deu p-valor 0,50 (não rejeita a raiz unitária, correto). Num ruído branco, o p-valor foi $\approx 10^{-29}$ (rejeita fortemente, correto).

10.3 Regressão espúria

Regredir uma série integrada contra outra, independente dela, produz coeficientes "significativos" com frequência absurda.

Conferido por simulação

Simulei 1000 pares de passeios aleatórios *independentes* com 200 observações cada, rodei MQO de um contra o outro e testei a inclinação a 5%. O teste t rejeitou a hipótese de inclinação zero em **83,6%** dos casos, em vez dos 5% esperados.



Esquerda: cinco passeios aleatórios independentes, que parecem ter tendências próprias. Direita: duas séries independentes que, por acaso, parecem relacionadas.

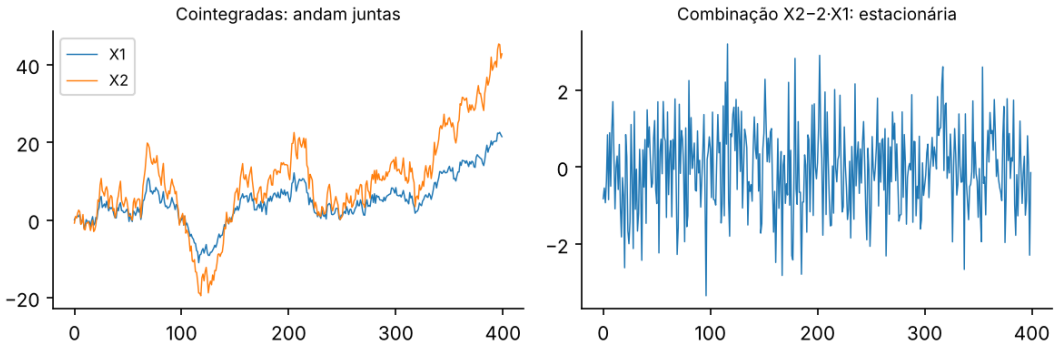
Regras práticas: (i) nunca faça MQO em níveis de séries com raiz unitária sem investigar cointegração; (ii) um sinal de alerta clássico é R^2 alto com resíduos fortemente autocorrelacionados (estatística de Durbin–Watson próxima de 0); (iii) se não há cointegração, trabalhe com as séries diferenciadas.

10.4 Cointegração

Duas séries $I(1)$ são **cointegradas** se alguma combinação linear delas é estacionária. Elas podem se afastar no curto prazo, mas uma força as traz de volta (um equilíbrio de longo prazo).

O bêbado e o cachorro

Dois passeios aleatórios independentes são como um bêbado e um cachorro soltos: cada um vai para onde quer. Cointegração é o bêbado com o cachorro na coleira: ambos vagam sem rumo, mas a distância entre eles é limitada.



$X_1 = w + \text{ruído}$ e $X_2 = 2w + \text{ruído}$, com w um passeio aleatório. Cada série é não estacionária, mas $X_2 - 2X_1$ é estacionária.

Teste de Engle–Granger (dois passos): (1) regrida uma série na outra; (2) aplique ADF aos resíduos, usando valores críticos *próprios* para resíduos estimados (mais exigentes que os do ADF comum). A alternativa multivariada é o teste de Johansen, que identifica quantas relações de cointegração existem.

Conferido por simulação

Com 200 observações, repeti 500 vezes. Para pares cointegrados, o teste de Engle–Granger a 5% rejeitou "sem cointegração" em 99,6% das simulações. Para pares independentes, rejeitou em 7,4% (um pouco acima dos 5% nominais em amostras de tamanho moderado, mas muito longe de 84%).

Modelo de correção de erros: se y_t e x_t são cointegradas, $\Delta y_t = \alpha(y_{t-1} - \beta x_{t-1}) + \gamma \Delta x_t + e_t$, com $\alpha < 0$ medindo a velocidade com que a economia retorna ao equilíbrio.

Exercício 10.1. Uma regressão entre duas séries de preços em nível dá $R^2 = 0{,}95$ e Durbin–Watson de 0,1. O que fazer antes de confiar nesse resultado?

Solução. O padrão (R^2 alto, DW muito baixo) é típico de regressão espúria. Teste raiz unitária em cada série; se ambas forem $I(1)$, teste cointegração (Engle–Granger ou Johansen). Sem cointegração, a regressão em níveis não tem interpretação e o correto é modelar as diferenças. Com cointegração, use um modelo de correção de erros.

Capítulo 11

Vetores autorregressivos (VAR)

11.1 O modelo

Um VAR(p) para um vetor de k variáveis é

$$y_t = c + A_1 y_{t-1} + \cdots + A_p y_{t-p} + u_t, \qquad \mathbb{E}(u_t) = 0, \quad \mathbb{E}(u_t u_t') = \Sigma.$$

Cada variável é explicada pelas defasagens de *todas* as variáveis, incluindo as suas próprias. A estimação por MQO, equação a equação, é consistente e, quando todas as equações têm os mesmos regressores, equivale à estimação de máxima verossimilhança (sob normalidade).

Estabilidade (estacionariedade): todos os autovalores da matriz companheira devem ter módulo menor que 1. É o análogo multivariado da condição $|\phi| < 1$.

11.2 Escolha do número de defasagens

Estime VARs com $p = 1, 2, \ldots, p_{\max}$ e compare AIC, BIC (ou Hannan–Quinn). Verifique que os resíduos não têm autocorrelação.

11.3 Causalidade de Granger

x *Granger-causa* y se as defasagens de x ajudam a prever y além das defasagens do próprio y. Testa-se com um teste F conjunto dos coeficientes de x na equação de y.

Armadilha: Granger não é causalidade

É uma noção de *precedência preditiva*. Se um terceiro fator, não incluído, move as duas variáveis com defasagens diferentes, aparece "causalidade de Granger" sem causa nenhuma. O nome é enganoso.

Conferido por simulação

Simulei um VAR(1) bivariado com $A = \begin{pmatrix} 0{,}5 & 0{,}2 \\ 0 & 0{,}4 \end{pmatrix}$ ($T = 1500$). Estimativa: $\hat{A} = \begin{pmatrix} 0{,}51 & 0{,}195 \\ -0{,}005 & 0{,}399 \end{pmatrix}$. Os autovalores de A têm módulos 0,5 e 0,4 (estável). O teste de Granger identificou corretamente: y_2 ajuda a prever y_1 (p-valor $\approx 10^{-15}$) e y_1 não ajuda a prever y_2 (p-valor 0,82).

11.4 Funções de resposta a impulso e decomposição da variância

A **resposta a impulso** mostra como cada variável reage, ao longo do tempo, a um choque numa equação. O problema: os erros u_t costumam ser correlacionados entre equações, então "um choque só em y_1" não existe sem uma hipótese adicional. A solução mais comum é a decomposição de Cholesky, que impõe uma ordem recursiva (a primeira variável afeta as demais no mesmo período, mas não o contrário).

Armadilha

A ordem das variáveis na decomposição de Cholesky muda os resultados quando os erros são correlacionados. Isso é uma escolha de identificação, e precisa ser justificada economicamente, não decidida por conveniência. A decomposição da variância do erro de previsão (FEVD) herda o mesmo problema.

Exercício 11.1. Um VAR(1) tem $A = \begin{pmatrix} 0{,}6 & 0{,}3 \\ 0{,}2 & 0{,}5 \end{pmatrix}$. Ele é estável?

Solução. Autovalores: $\lambda^2 - (0{,}6+0{,}5)\lambda + (0{,}6\cdot 0{,}5 - 0{,}3\cdot 0{,}2) = \lambda^2 - 1{,}1\lambda + 0{,}24 = 0$. Então $\lambda = (1{,}1 \pm \sqrt{1{,}21 - 0{,}96})/2 = (1{,}1 \pm 0{,}5)/2$, isto é, 0,8 e 0,3. Ambos têm módulo menor que 1: o VAR é estável.

Capítulo 12

Volatilidade: ARCH e GARCH

12.1 O problema

Retornos financeiros têm três traços estáveis: (i) quase sem autocorrelação, (ii) *quadrados* dos retornos fortemente autocorrelacionados (a volatilidade vem em ondas: calmaria, turbulência), (iii) caudas mais pesadas do que as de uma normal. Um ARMA clássico supõe variância constante e não captura nada disso.

12.2 ARCH(1) e GARCH(1,1)

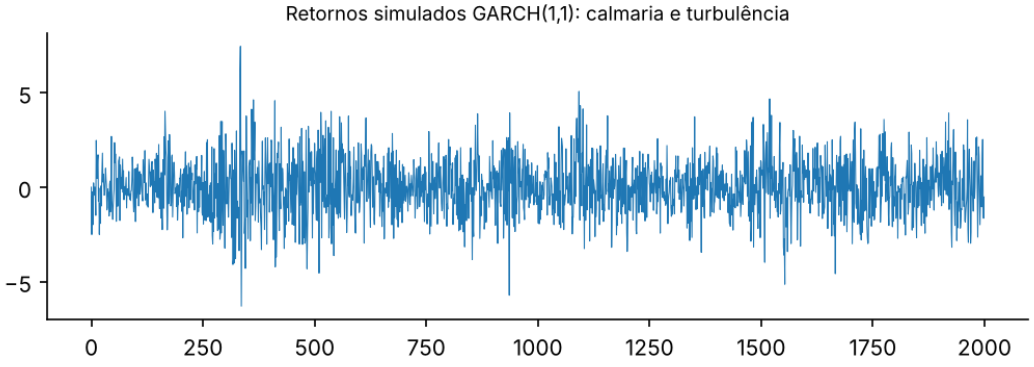
Escreva o retorno (já sem média) como $r_t = \sigma_t z_t$, com z_t i.i.d. de média 0 e variância 1. No **GARCH(1,1)**:

$$\sigma_t^2 = \omega + \alpha\, r_{t-1}^2 + \beta\, \sigma_{t-1}^2, \qquad \omega > 0,\ \alpha, \beta \geq 0.$$

- O ARCH(1) é o caso $\beta = 0$: a volatilidade de hoje depende só do choque de ontem.
- **Estacionariedade**: $\alpha + \beta < 1$. Variância incondicional: $\omega/(1-\alpha-\beta)$.
- $\alpha + \beta$ mede a **persistência**. Valores próximos de 1 (como 0,97) são típicos em dados reais.
- A curtose (de r_t) é maior do que 3 mesmo com z_t normal.

Conferido por simulação

Com $\omega = 0{,}1$, $\alpha = 0{,}1$, $\beta = 0{,}85$ e uma simulação longa (400 mil pontos): variância 2,009 (teoria: $0{,}1/0{,}05 = 2$); curtose 3,774 (teoria: 3,774); autocorrelação de r_t^2 no lag 1: 0,177 (teoria: 0,179). A autocorrelação de r_t ficou próxima de zero (0,04 numa amostra de 2000 pontos), mas a de r_t^2 foi 0,15. Ruído branco nos retornos, dependência forte na volatilidade.



Estimação: parâmetros individuais são difíceis

Ajustando um GARCH(1,1) a 2000 pontos simulados, obtive $\hat{\omega} = 0{,}054$, $\hat{\alpha} = 0{,}086$ e $\hat{\beta} = 0{,}890$, contra os verdadeiros 0,1; 0,1; 0,85. Os parâmetros individuais erraram bastante, mas a combinação que importa ficou próxima: persistência estimada 0,976 (verdadeira 0,95) e variância incondicional $0{,}054/0{,}024 \approx 2{,}26$ (verdadeira 2,0). Em modelos muito persistentes, ω, α e β ficam fortemente correlacionados na estimação.

Armadilha

- **Não aplique ARCH a uma série com raiz unitária ou tendência**; trabalhe com retornos (diferenças de logaritmos).
- **O GARCH simétrico não distingue notícias boas de ruins.** Para o efeito alavancagem (quedas aumentam mais a volatilidade do que altas), use GJR-GARCH ou EGARCH.
- **Escolher z_t normal subestima caudas**; muitos usam t de Student.

Exercício 12.1. GARCH(1,1) com $\omega = 0{,}2$, $\alpha = 0{,}1$, $\beta = 0{,}8$. Calcule a variância incondicional e a previsão de σ^2_{t+1} dado $r^2_t = 4$ e $\sigma^2_t = 3$.

Solução. Variância incondicional: $0{,}2/(1 - 0{,}9) = 2$. Previsão:
$\sigma^2_{t+1} = 0{,}2 + 0{,}1 \times 4 + 0{,}8 \times 3 = 0{,}2 + 0{,}4 + 2{,}4 = 3{,}0$.

Exercício 12.2. Por que $\alpha + \beta = 1$ cria problemas, e como se chama esse caso?

Solução. Com $\alpha + \beta = 1$ a variância incondicional não existe (o denominador é zero) e choques de volatilidade nunca se dissipam. É o IGARCH. A previsão da volatilidade futura deixa de reverter para uma média de longo prazo.

Capítulo 13

Aprendizado de máquina para séries temporais

13.1 O que muda quando os dados têm ordem

Os métodos de aprendizado de máquina (florestas aleatórias, *boosting*, redes neurais) foram desenhados, em sua maioria, para observações independentes. Em séries temporais, três cuidados são obrigatórios.

13.1.1 Validação cruzada que respeita o tempo

A validação cruzada aleatória (*k-fold* com embaralhamento) mistura passado e futuro. Como observações vizinhas são parecidas, o modelo "vê" pontos quase idênticos ao que vai prever. Isso vaza informação e subestima o erro.

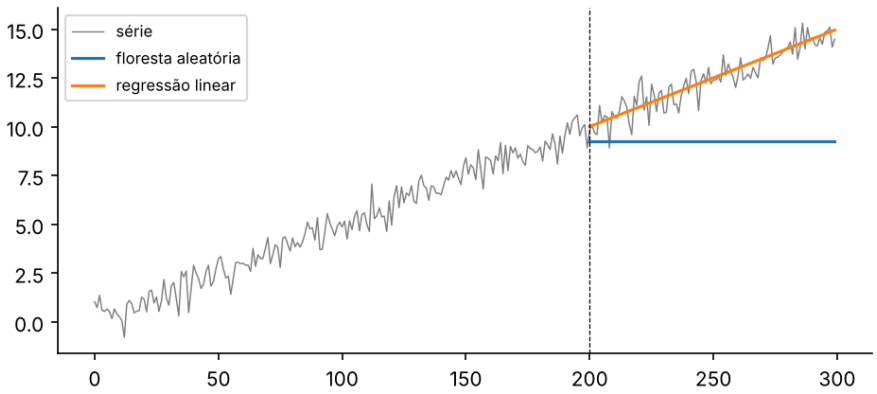
Conferido por simulação: vazamento na validação

Série AR(1) muito persistente ($\phi = 0{,}98$, ruído de desvio-padrão 1), floresta aleatória com 5 defasagens como variáveis explicativas. RMSE com validação cruzada aleatória: 1,08. RMSE com validação temporal (treino no passado, teste no futuro): 1,49. O ruído irredutível é 1,0. O procedimento aleatório parece quase perfeito. O temporal mostra o desempenho real, bem pior. A diferença é puro vazamento.

Use sempre **validação com janela móvel ou expansiva** (origem móvel, como no capítulo 9), e, quando houver sobreposição entre janelas, deixe uma folga (*gap*) entre treino e teste.

13.1.2 Árvores não extrapolam

Uma árvore (e uma floresta) prevê médias de observações já vistas. Se a série tem tendência e o futuro sai do intervalo do treino, ela fica "presa" no último patamar.



Série com tendência linear. A floresta aleatória, treinada até $t = 200$, prevê um patamar plano; a regressão linear continua a tendência.

Conferido por simulação

No ponto $t = 299$, a floresta previu 9,27, e o valor da tendência é 14,95.

Soluções: diferenciar ou remover a tendência antes de ajustar, modelar a variação em vez do nível, ou usar um modelo híbrido (tendência linear mais floresta nos resíduos).

13.1.3 Construção das variáveis explicativas

Para transformar previsão em problema de regressão: use defasagens $(y_{t-1}, \ldots, y_{t-p})$, médias móveis, variáveis de calendário (mês, dia da semana, feriados) e regressores externos. Qualquer estatística construída com dados do futuro (por exemplo, normalizar com a média da série inteira) é vazamento.

13.2 Duas famílias úteis

- **Modelos globais**: em vez de ajustar um modelo por série, treina-se um único modelo (por exemplo, uma rede neural recorrente ou um *boosting*) com milhares de séries. Ajuda quando cada série é curta ou ruidosa. É a ideia central do tutorial de Faloutsos e coautores sobre previsão em larga escala.
- **Classificação de séries**: o problema não é prever, mas atribuir um rótulo a uma série inteira (por exemplo, normal versus anomalia num eletrocardiograma). É o foco do pacote `pyts`, que oferece técnicas como *dynamic time warping*, *shapelets* e representações em imagem. Não confunda com previsão.

Armadilhas

- **Sempre compare com o previsor ingênuo e com um ARIMA/ETS**. Muitos resultados deslumbrantes de redes profundas desaparecem diante de um *benchmark* simples.
- **Intervalos de previsão**: modelos de ML dão previsões pontuais. Para incerteza, use

regressão por quantis, *conformal prediction* ou simulação.

- **Hiperparâmetros ajustados nos dados de teste**: o teste deve ser tocado uma única vez.

Exercício 13.1. Por que embaralhar as observações antes de dividir em treino e teste é um erro numa série temporal?

Solução. Porque faz o modelo treinar com observações do futuro e testar no passado, e porque observações adjacentes são fortemente dependentes: pontos de teste têm quase-duplicatas no treino. O erro estimado fica irrealisticamente baixo. O teste correto respeita a ordem cronológica.

Parte V

Consulta rápida

Capítulo 14

Cola de armadilhas e convenções

Esta lista reúne os pontos em que livros, softwares e intuições costumam divergir. Cada item aparece no capítulo indicado.

#	Armadilha	Conduta correta
1	Tomar $\mathbb{E}(u \mid x) = 0$ como necessário para consistência do MQO (cap. 3)	Basta $\mathbb{E}(x'u) = 0$. A hipótese condicional é necessária para a interpretação como esperança condicional e para resultados de amostra finita.
2	Corrigir heterocedasticidade só depois de "testar" (cap. 3)	Reporte erros robustos diretamente: valem nos dois casos.
3	Esquecer que erro robusto a heterocedasticidade não corrige autocorrelação (cap. 3, 6)	HAC em séries, erros agrupados em painéis.
4	Interpretar viés de variável omitida sem checar os dois sinais (cap. 4)	O viés é $\beta_2\delta_1$. O sinal é o produto dos dois.
5	Esperar que erro de medida sempre atenue (cap. 4)	Só vale para erro clássico num regressor. Com vários regressores ou erro não clássico, o efeito é incerto.
6	Rodar o 2º estágio de VI à mão (cap. 5)	Use um comando de MQ2E, que corrige os erros-padrão.
7	Confiar na regra "F > 10" como garantia (cap. 5)	É um mínimo. Reporte também intervalos robustos a instrumentos fracos.
8	Usar Hausman clássico com erros robustos (cap. 6)	Use a versão de Mundlak com erros agrupados.
9	Esquecer que efeitos fixos exigem exogeneidade estrita (cap. 6)	Com defasagem da dependente ou *feedback*, use painel dinâmico (GMM).
10	Copiar fórmula de MA de um livro e coeficiente de um software sem checar o sinal (cap. 7)	Cryer–Chan e Mills: $\varepsilon_t - \theta\varepsilon_{t-1}$. Hamilton, R, `statsmodels`: $\varepsilon_t + \theta\varepsilon_{t-1}$.
11	Usar bandas $\pm 1{,}96/\sqrt{n}$ como veredito (cap. 7)	Valem sob ruído branco. Para outras séries, as bandas são mais largas.
12	Ljung–Box com m graus de liberdade em resíduos de ARMA (cap. 8)	Use $m - p - q$.
13	Comparar a estatística ADF com $-1{,}96$ (cap. 10)	Use valores críticos de Dickey–Fuller (cerca de $-2{,}86$ a 5% com constante).
14	Regredir séries integradas em nível (cap. 10)	Teste cointegração. Se não houver, diferencie.
15	Supor que o intervalo de previsão tem cobertura exata (cap. 9)	Ele ignora incerteza dos parâmetros e do modelo. Avalie a cobertura fora da amostra.
16	Ler Granger como causalidade (cap. 11)	É precedência preditiva.
17	Ignorar a ordem de Cholesky nas respostas a impulso (cap. 11)	A ordem é uma hipótese de identificação e muda os resultados.

#	**Armadilha**	**Conduta correta**
18	Interpretar ω, α, β isoladamente em GARCH persistente (cap. 12)	Olhe a persistência $\alpha + \beta$ e a variância incondicional.
19	Validação cruzada aleatória em séries (cap. 13)	Validação temporal, com origem móvel.
20	Esperar que árvores extrapolem tendência (cap. 13)	Remova a tendência ou use modelo híbrido.

Roteiro de estudo sugerido

1. Capítulos 1 a 3: faça todos os exercícios, à mão.
2. Capítulos 4 e 5: replique as simulações em Python ou R, mudando os parâmetros, até prever o resultado antes de rodar.
3. Capítulo 6: monte um painel simulado com c_i correlacionado e descorrelacionado e compare os estimadores.
4. Capítulos 7 a 9: ajuste ARIMA a uma série real, faça o diagnóstico e a avaliação com origem móvel.
5. Capítulos 10 a 12: teste raiz unitária e cointegração em pares de séries de preços; estime um GARCH em retornos diários.
6. Capítulo 13: reproduza o vazamento da validação cruzada e depois resolva com validação temporal.